

Identificação de Padrões Espaciais em Focos de Incêndio no Brasil: Uma Abordagem Comparativa entre K-Means, GMM e DBSCAN para o ODS 15

Vinícius de Oliveira Elias

Disciplina de Inteligência Artificial – Prof. Didier A. Vega-Oliveros

Resumo—O monitoramento e a mitigação de incêndios florestais são desafios centrais para a preservação da biodiversidade, alinhando-se aos Objetivos de Desenvolvimento Sustentável (ODS 15 – Vida Terrestre). Este artigo propõe uma análise espacial não supervisionada sobre uma base de dados real do INPE (BDQueimadas) contendo mais de 284 mil focos de queimadas no Brasil, dos quais 136 mil com FRP válido ($n > 1000$). Diferentemente de abordagens puramente geométricas, o vetor de atributos foi ampliado com a Potência Radiativa do Fogo (FRP), permitindo que os algoritmos identifiquem aglomerados espaciais de alta intensidade destrutiva. Foram implementados e comparados três algoritmos de agrupamento: K-Means, *Gaussian Mixture Model* (GMM) e DBSCAN. A avaliação estatística, conduzida através de 30 execuções independentes, evidenciou a superioridade metodológica do DBSCAN, que atingiu um Coeficiente de Silhueta médio de 0,4619 frente a 0,3554 do K-Means e 0,0474 do GMM. Um teste de hipótese de Kruskal-Wallis ($p < 10^{-12}$) confirmou que a diferença é estatisticamente significativa. Os resultados comprovam que a natureza não linear e assimétrica da propagação do fogo exige modelos guiados por densidade, superando as limitações topológicas de aglomerados esféricos ou elípticos.

Index Terms—Inteligência Artificial, Mineração de Dados, DBSCAN, K-Means, ODS 15, Incêndios Florestais, Coeficiente de Silhueta.

I. INTRODUÇÃO

O colapso progressivo dos biomas terrestres, catalisado pela propagação de incêndios florestais descontrolados, ameaça a biodiversidade endêmica e exacerba a emissão de gases de efeito estufa [8]. A contenção destas catástrofes depende substancialmente da capacidade analítica de prever e detectar padrões espaço-temporais de degradação, o que coloca a inteligência artificial (IA) como ferramenta indispensável para o cumprimento das metas da Agenda 2030, especificamente o ODS 15.

Neste contexto, o presente trabalho tem como objetivo principal aplicar técnicas de mineração de dados espaciais [1], [9] para identificar zonas endêmicas de incêndios florestais no território brasileiro. A pesquisa transcende a aplicação elementar de algoritmos ao utilizar microdados reais com um elevado número de instâncias.

A contribuição central deste estudo reside na avaliação empírica comparativa entre modelos paramétricos que assumem formatos pré-definidos de agrupamento (como K-Means e GMM) e modelos baseados em densidade (DBSCAN), que mapeiam a continuidade orgânica das áreas afetadas [2]. Adicionalmente, ampliamos o escopo clássico ao incorporar

a Potência Radiativa do Fogo (FRP) ao vetor de atributos e ao realizar uma análise segmentada por bioma, contrastando a forma dos incêndios no Cerrado e na Amazônia. O trabalho está organizado da seguinte forma: a Seção II discute a literatura pertinente; a Seção III detalha a engenharia de dados, a fundamentação matemática e os algoritmos empregados; a Seção IV apresenta os experimentos e resultados estatísticos; e, por fim, a Seção V encerra com as conclusões e trabalhos futuros.

II. TRABALHOS RELACIONADOS

A literatura contemporânea apresenta diversas abordagens computacionais focadas no monitoramento da degradação florestal. Para situar este trabalho, destacam-se cinco pesquisas de relevância teórica e aplicada.

Primeiramente, no campo do agrupamento particional, autores aplicaram o K-Means não supervisionado sobre imagens de satélite Sentinel para detectar polígonos de desmatamento na Amazônia [5]. O problema abordado foi a segmentação automática de áreas degradadas a partir de bandas espectrais, e os autores obtiveram uma discretização razoável das regiões. Contudo, o método esbarra na suscetibilidade a ruídos e na premissa de clusters convexos, agrupando artificialmente áreas desconexas unicamente pela proximidade linear. Nossa abordagem utiliza o K-Means apenas como linha de base e demonstra empiricamente essa limitação frente às manchas orgânicas do fogo.

Em segundo lugar, o algoritmo DBSCAN foi originalmente proposto como um método de agrupamento baseado em densidade voltado à descoberta de classes em grandes bases de dados espaciais na presença de ruído [2]. O problema central abordado pelos autores era identificar agrupamentos de formato arbitrário sem exigir a definição prévia do número de grupos e com requisitos mínimos de conhecimento de domínio, tratando pontos isolados como ruído. Apoiamo-nos nessa fundamentação teórica ao transpô-la para o domínio das queimadas, estendendo o vetor de características com a FRP para buscar não apenas agrupamentos espaciais, mas concentrações de alta intensidade radiativa, e validando os clusters via Coeficiente de Silhueta e teste de hipótese.

Em terceiro lugar, avançando na dimensão temporal, o algoritmo ST-DBSCAN (*Spatial-Temporal* DBSCAN) estendeu o DBSCAN por meio de três modificações que permitem agrupar objetos considerando simultaneamente valores não

espaciais, espaciais e temporais [7]. Essa formulação processa os dados não como fotografias estáticas, mas incorporando a continuidade temporal, o que a torna promissora para o mapeamento de corredores de propagação. Nossa proposta é deliberadamente espacial e de intensidade (menor custo computacional), deixando a componente temporal como trabalho futuro apoiado nesse algoritmo.

Em quarto lugar, no campo preditivo estruturado, uma abordagem supervisionada e sensível ao contexto departamental foi proposta para a predição do risco de incêndios florestais, argumentando que o risco não deve ser assumido como uniforme entre regiões, mas ajustado às condições locais de cada unidade territorial [8]. Os autores introduziram uma nova base de dados e o primeiro *benchmark* nacional de IA em escala metropolitana para a França, empregando modelos do estado da arte. Diferentemente, nosso método é descritivo e não supervisionado, dispensando rótulos de risco e oferecendo uma exploração de padrões de menor custo de anotação; ainda assim, convergimos com esse trabalho ao constatar, em nossa análise por bioma, que a calibração regionalizada dos modelos é decisiva.

Por fim, o uso de Aprendizado Profundo (*Deep Learning*) foi investigado para a detecção de anomalias florestais nos biomas da Amazônia e Cerrado [6]. Redes Neurais Convolucionais (CNN) foram utilizadas para segmentar focos com alta precisão, ao custo de um poder computacional avassalador e de grandes repositórios rotulados. Em contraste, nossa solução opera apenas sobre coordenadas vetoriais (Latitude e Longitude) acrescidas da FRP, oferecendo um custo computacional drasticamente menor, adequado a secretarias de segurança ambiental com recursos limitados.

III. METODOLOGIA

A fundamentação metodológica operou na convergência entre o pré-processamento ambiental e a parametrização de agrupamentos não-supervisionados.

A. Pré-Processamento Espacial

A matriz bruta sofreu a remoção estrita de dados corrompidos (ausências preenchidas como -999). O vetor de atributos foi composto por três dimensões: Latitude, Longitude e FRP. Para evitar que algoritmos sensíveis a distâncias tivessem o desempenho degradado pela disparidade de escalas (coordenadas geográficas *versus* potência radiativa em MW), aplicou-se compulsoriamente a padronização *Z-score* (*StandardScaler*), de modo que cada eixo passou a ter média zero e variância unitária [1].

B. Fundamentação Matemática

K-Means. Método particional clássico [1], [9], o algoritmo particiona o conjunto em k grupos minimizando a inércia, isto é, a soma das distâncias euclidianas quadráticas de cada ponto ao centróide μ_j do seu cluster C_j :

$$J = \sum_{j=1}^k \sum_{x_i \in C_j} \|x_i - \mu_j\|^2. \quad (1)$$

A minimização iterativa de (1) pressupõe agrupamentos convexos e de densidade homogênea, o que o torna sensível a *outliers* e a formas alongadas.

DBSCAN. O agrupamento baseado em densidade [2] dispensa a definição prévia do número de grupos. Um ponto p é classificado como *core* se a sua ϵ -vizinhança contiver pelo menos $MinPts$ instâncias:

$$|N_\epsilon(p)| \geq MinPts, \quad N_\epsilon(p) = \{q \mid d(p, q) \leq \epsilon\}. \quad (2)$$

Clusters são expandidos por alcançabilidade por densidade a partir dos pontos *core*, enquanto instâncias não alcançáveis são rotuladas como ruído. Essa mecânica permite acompanhar corredores arbitrários de queimada e isolar focos dispersos.

Coefficiente de Silhueta. A qualidade intrínseca dos agrupamentos foi medida pelo Coeficiente de Silhueta [3]. Para cada instância i , sejam $a(i)$ a distância média intra-cluster e $b(i)$ a menor distância média a um cluster vizinho. A silhueta de i é:

$$S(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}}, \quad S(i) \in [-1, 1]. \quad (3)$$

O índice global é a média de $S(i)$ sobre todas as instâncias; valores próximos de 1 indicam agrupamentos coesos e bem separados.

C. Mecanismos de Decisão e Algoritmos

- **K-Means:** algoritmo partitivo que define clusters esféricos minimizando a inércia da Eq. (1) (definido empiricamente como $k = 8$).
- **Gaussian Mixture Model (GMM):** expansão probabilística do K-Means que estima distribuições gaussianas multivariadas. A matriz de covariância foi configurada como plena (*full*), permitindo formatos elípticos de detecção.
- **DBSCAN:** agrupamento baseado em densidade com raio de vizinhança $\epsilon = 0,30$ e cardinalidade mínima $MinPts = 15$. Esses hiperparâmetros foram selecionados por varredura sistemática de valores candidatos no espaço tridimensional (Lat/Long/FRP), adotando-se a configuração que maximiza o Coeficiente de Silhueta, conforme o estudo de variação de parâmetros apresentado na Seção IV.

IV. ANÁLISE EXPERIMENTAL

A. Conjunto de Dados

A pesquisa utilizou o registro governamental consolidado (BDQueimadas) do Instituto Nacional de Pesquisas Espaciais (INPE), referente ao ano de 2025 [4]. A base contempla 284.152 focos geolocalizados nos biomas Amazônia, Cerrado, Caatinga, Mata Atlântica, Pantanal e Pampa. Após a exigência de FRP válida para a composição do vetor tridimensional, 136.393 instâncias compuseram a análise, superando amplamente o limite estipulado pela disciplina ($n > 1000$).

A análise exploratória (Fig. 1) revela duas características determinantes. A distribuição da FRP é fortemente assimétrica, com a maioria dos focos concentrada em baixas potências e uma longa cauda de eventos de altíssima intensidade —





Figura 1. Análise exploratória dos dados. À esquerda, histograma da FRP (eixo y em escala logarítmica), evidenciando a forte assimetria. À direita, distribuição geográfica dos focos coloridos por bioma.

justamente os *outliers* que penalizam modelos baseados em centróides. Geograficamente, os focos formam manchas densas e contíguas no Cerrado e na Amazônia, intercaladas por focos esparsos, padrão que motiva o uso de algoritmos sensíveis à densidade.

B. Configuração do Algoritmo e do Ambiente Computacional

Os ensaios foram codificados em Python 3.12.10, empregando as bibliotecas *scikit-learn* 1.9.0, *pandas* 3.0.4, *numpy* 2.5.0, *scipy* 1.18.0, *matplotlib* 3.11.0 e *seaborn* 0.13.2. O ambiente de execução foi um notebook com processador Intel Core i5-10210U (4 núcleos, 8 *threads*, *clock* base de 1,60 GHz e máximo de 2,10 GHz), 16 GB de memória RAM, sob o sistema operacional Microsoft Windows 10 Pro (*build* 10.0.19045).

C. Critérios de Análise e Rigor Estatístico

Garantindo a estabilidade matemática dos resultados, os métodos foram testados em 30 iterações independentes. A cada rodada, 80% do conjunto de dados era re-amostrado mediante sementes aleatórias declaradas (*random seeds*) atreladas a uma variável iterativa, assegurando reprodutibilidade. É crucial destacar que o *fit* dos algoritmos ocorreu sobre essa base densa de ≈ 109 mil pontos, preservando a estrutura de densidade exigida pelo DBSCAN. Para mitigar o custo $\mathcal{O}(n^2)$ do Coeficiente de Silhueta, o cálculo da métrica utilizou subamostragem interna de 5.000 instâncias por ciclo, monitorando-se simultaneamente o tempo de execução (em segundos). No caso do DBSCAN, os pontos rotulados como ruído (−1) foram excluídos do cálculo da silhueta, uma vez que o ruído não constitui um agrupamento coeso; K-Means e GMM não produzem esse rótulo. Por fim, aplicou-se o teste não-paramétrico de Kruskal-Wallis sobre as distribuições de silhueta das 30 execuções, adequado por não pressupor normalidade dos dados.

D. Resultados e Discussão

A Tabela I sumariza o desempenho médio das 30 execuções. Os dados empiricamente levantados atestaram que os modelos baseados em centróides se provam insuficientes para fenômenos ecológicos de dispersão orgânica.

Tabela I
RESUMO ESTATÍSTICO DAS 30 EXECUÇÕES INDEPENDENTES
COMPARANDO A QUALIDADE DE AGRUPAMENTO ESPACIAL E O CUSTO COMPUTACIONAL.

Métrica Média (30x)	K-Means	GMM	DBSCAN
Coef. Silhueta (média)	0,3554	0,0474	0,4619
Coef. Silhueta (mediana)	0,3553	0,0373	0,5177
Desvio Padrão (Silhueta)	$\pm 0,004$	$\pm 0,025$	$\pm 0,172$
Tempo médio (s)	1,69	5,30	15,38
Desvio Padrão (Tempo, s)	$\pm 0,28$	$\pm 0,70$	$\pm 1,72$

O particionamento tradicional (K-Means) foi prejudicado pelas manchas contorcidas do fogo e por *outliers* de FRP, atingindo silhueta de 0,3554. A transição para elipses probabilísticas via GMM **degradou** o resultado (0,0474): a inclusão da intensidade radiativa, fortemente assimétrica, viola a premissa de componentes gaussianas, dispersando as probabilidades. Em notória superioridade, o DBSCAN alcançou silhueta média de 0,4619 (mediana 0,5177), mapeando corredores contínuos de queimada e segregando focos isolados como ruído (−1). Na configuração adotada, o algoritmo identificou de 3 a 4 agrupamentos densos rotulando apenas $\approx 1,4\%$ das instâncias como ruído. O acréscimo no tempo de convergência (15,38 s) reflete o processamento sobre a base densa, mas não inviabiliza a solução para gestores públicos. Cabe observar que esse valor médio é inferior ao registrado no estudo de variação de parâmetros para o mesmo $\epsilon = 0,30$ (0,6407): aquele corresponde a uma única execução de semente fixa, ao passo que o experimento principal promedia 30 subconjuntos de 80% reamostrados de forma independente. O elevado desvio-padrão

($\pm 0,172$, ante $\pm 0,004$ do K-Means) evidencia a sensibilidade do DBSCAN à composição da amostra, instabilidade que deve ser ponderada em sua adoção operacional. Por fim, a comparação por silhueta é influenciada pelo número de agrupamentos — o DBSCAN forma de 3 a 4 clusters, ante $k = 8$ dos demais —, o que tende a favorecer configurações com menos grupos bem separados; mesmo assim, sua superioridade se mantém inclusive no k ótimo do K-Means.

O teste de hipótese de Kruskal-Wallis sobre as silhuetas das 30 execuções resultou em estatística $H = 57,32$ e $p\text{-valor} = 3,6 \times 10^{-13}$. Como $p \ll 0,05$, rejeita-se a hipótese nula de igualdade entre as distribuições, comprovando estatisticamente que a vantagem do DBSCAN não é fruto do acaso. A Fig. 2 ilustra graficamente essa separação entre as distribuições.




Figura 2. Distribuição do Coeficiente de Silhueta ao longo das 30 execuções independentes para cada algoritmo. O DBSCAN concentra-se em patamares superiores, com mediana destacadamente mais alta.




Figura 3. Dispersão geográfica dos focos de incêndio (Longitude $\times$ Latitude padronizadas), coloridos pelos clusters identificados pelo DBSCAN. Observam-se aglomerados contínuos e a segregação de focos esparsos.

E. Estudo de Variação de Parâmetros

Conforme exigido pela disciplina, avaliou-se a influência dos hiperparâmetros sobre a qualidade do agrupamento (Fig. 4). Para o K-Means, variou-se o número de clusters $k \in [2, 12]$: a silhueta atinge seu máximo em $k = 5$ (0,4049) e decai para configurações mais fragmentadas. Note-se que, mesmo em seu ponto ótimo, o K-Means permanece bem abaixo do DBSCAN, reforçando que a limitação não é de parametrização, mas de premissa topológica. Para o DBSCAN, variou-se o raio ϵ : valores pequenos ($\epsilon = 0,10$) fragmentam excessivamente o espaço e produzem silhueta negativa, enquanto a métrica cresce monotonicamente até o pico em $\epsilon = 0,30$ (0,6407), ponto em que apenas 1,3% dos pontos são ruído. Essa análise de sensibilidade justifica empiricamente a calibração adotada e demonstra a forte dependência do método à escolha de ϵ .

F. Análise Segmentada por Bioma

Para investigar como a geografia altera a morfologia dos incêndios, repetiu-se a análise isoladamente para os dois biomas mais representativos. A Tabela II evidencia um comportamento heterogêneo: no Cerrado, de vegetação mais homogênea, o DBSCAN obteve forte silhueta (0,5924); na Amazônia, cuja densidade de focos é mais difusa, o índice do DBSCAN com a configuração global ($\epsilon = 0,30$) caiu para 0,2941, abaixo do K-Means. Contudo, ao **recalibrar ϵ por bioma**, o DBSCAN da Amazônia recupera-se para 0,4455 (com $\epsilon = 0,40$), voltando a superar o K-Means local. Esse resultado demonstra que a eficácia dos modelos de densidade depende da continuidade espacial de cada bioma e que a parametrização regionalizada é uma estratégia promissora.

Tabela II
COEFICIENTE DE SILHUETA POR BIOMA. A ÚLTIMA COLUNA RECALIBRA ϵ ESPECIFICAMENTE PARA CADA BIOMA.

Bioma	K-Means	GMM	DBSCAN ($\epsilon = 0,30$)	DBSCAN (recal.)
Cerrado	0,3795	0,0260	0,5924	0,5924 $\epsilon = 0,30$
Amazônia	0,3942	0,0829	0,2941	0,4455 $\epsilon = 0,40$

V. CONCLUSÕES

O presente trabalho consolidou com êxito a aplicação da Inteligência Artificial voltada à Agenda 2030. A formulação e os testes exaustivos na base do INPE permitiram comprovar empiricamente que a extração de inteligência em ecossistemas de alta dispersão natural depende não do particionamento distancial, mas da coerência orgânica avaliada por algoritmos de densidade. O DBSCAN, mesmo com o vetor de atributos ampliado pela FRP, provou ser um instrumento justificado, estável e estatisticamente superior ($p < 10^{-12}$) para identificar frentes ativas de destruição. O estudo de variação de parâmetros confirmou que essa vantagem é estrutural — o K-Means não a alcança nem em seu k ótimo. A análise por bioma, por sua vez, revelou que a superioridade do DBSCAN é sensível




Figura 4. Estudo de variação de parâmetros. À esquerda, silhueta do K-Means em função de k (pico em $k = 5$). À direita, silhueta e percentual de ruído do DBSCAN em função de ϵ (pico em $\epsilon = 0,30$).

à geografia local, sendo expressiva no Cerrado e recuperável na Amazônia apenas mediante a recalibração regionalizada de ϵ .

Como propostas para trabalhos futuros, sugere-se a integração da variável de registro cronológico disponível no *dataset*, migrando a inferência para um contexto espaço-temporal com o algoritmo ST-DBSCAN [7], e a calibração automática de ϵ por bioma, fornecendo às autoridades um mapeamento não só espacial, mas de velocidade de propagação temporal.

REFERÊNCIAS

- [1] J. Han, M. Kamber, and J. Pei, *Data Mining: Concepts and Techniques*, 3rd ed. Morgan Kaufmann, 2011.
- [2] M. Ester, H.-P. Kriegel, J. Sander, and X. Xu, “A density-based algorithm for discovering clusters in large spatial databases with noise,” in *Proc. KDD*, 1996, pp. 226–231.
- [3] P. J. Rousseeuw, “Silhouettes: A graphical aid to the interpretation and validation of cluster analysis,” *J. Comput. Appl. Math.*, vol. 20, pp. 53–65, 1987.
- [4] Instituto Nacional de Pesquisas Espaciais (INPE), “Programa Queimadas / TerraBrasilis.” [Online]. Disponível: <https://terrabrasilis.dpi.inpe.br/>
- [5] Esri Developer, “Detecting deforestation in the Amazon rainforest using unsupervised K-means clustering on satellite imagery,” ArcGIS API for Python, 2024.
- [6] M. Ortega Adarme, R. Q. Feitosa, P. N. Happ, C. A. De Almeida, and A. R. Gomes, “Evaluation of deep learning techniques for deforestation detection in the Brazilian Amazon and Cerrado biomes from remote sensing imagery,” *Remote Sensing*, vol. 12, no. 6, p. 910, 2020.
- [7] D. Birant and A. Kut, “ST-DBSCAN: An algorithm for clustering spatial-temporal data,” *Data Knowl. Eng.*, vol. 60, no. 1, pp. 208–221, 2007.
- [8] N. Caron, H. Noura, C. Guyeux, and B. Aynes, “Localized forest fire risk prediction: A department-aware approach for operational decision support,” arXiv preprint arXiv:2506.04254, 2025.
- [9] K. Faceli, A. C. Lorena, J. Gama, and A. C. P. L. F. de Carvalho, *Inteligência Artificial: Uma Abordagem de Aprendizado de Máquina*. Rio de Janeiro: LTC, 2011.